

2do Examen Parcial

Uso de Keras — Predicción de Calidad del Agua (India)

Documento de Resultados, Análisis y Conclusiones

Autores: Mauricio Raba, Jorge Gómez, Tomás Fonseca, Daniel Galvis
Profesor: John Corredor
Fecha: 28/04/2026

1. Descripción del Dataset

El dataset utilizado corresponde a mediciones de parámetros fisicoquímicos y bacteriológicos de ríos en diferentes estados de la India (fuente: RiverIndia — datos oficiales del gobierno de la India). Cada registro representa el promedio de valores medidos durante un período de tiempo en una estación de monitoreo específica.

El archivo waterquality.csv contiene las siguientes variables:

Parámetro	Descripción	Unidad	Rango Óptimo
TEMP	Temperatura del agua	°C	15 – 25
DO	Oxígeno Disuelto	mg/L	≥ 6.0
pH	Nivel de acidez/basicidad	adim.	7.0 – 8.5
CONDUCTIVITY	Conductividad eléctrica	μS/cm	0 – 75
BOD	Demanda Bioquímica de O ₂	mg/L	< 3.0
NITRATE_N_NITRITE_N	Nitratos/Nitritos	mg/L	< 20.0
FECAL_COLIFORM	Coliformes fecales	UFC/100mL	< 5.0
TOTAL_COLIFORM	Coliformes totales (excluido)	—	—

Nota: la columna TOTAL_COLIFORM fue eliminada durante el preprocesamiento por no aportar información discriminante para la predicción del índice WQI, según el criterio metodológico del notebook de referencia.

2. Preprocesamiento y Limpieza de Datos

2.1 Verificación de valores nulos

Mediante la función `F.isnan()` | `F.col(c).isNull()` aplicada sobre todas las columnas del dataframe PySpark, se verificó que el dataset no contiene valores nulos ni imposibles en ninguna de las variables relevantes. Este resultado es favorable, ya que evita la necesidad de imputación en la etapa inicial.

Adicionalmente, se creó una vista temporal `df01` filtrando registros donde las 7 variables de análisis sean no nulas (cláusula SQL `WHERE`), lo cual actúa como una capa de seguridad redundante.

2.2 Transformación de tipos de datos

Todas las columnas numéricas estaban almacenadas originalmente como `StringType` (comportamiento estándar al leer CSV en PySpark sin schema explícito). Se realizó un `cast` explícito a `FloatType` para cada variable de análisis: `TEMP`, `DO`, `pH`, `CONDUCTIVITY`, `NITRATE_N`, `NITRITE_N`, `FECAL_COLIFORM` y `BOD`.

2.3 Eliminación de columna `TOTAL_COLIFORM`

La columna `TOTAL_COLIFORM` fue removida del dataframe mediante `df00.drop('TOTAL_COLIFORM')`, reduciendo la dimensionalidad del dataset y enfocando el análisis en las variables con mayor relevancia para el cálculo del WQI según la literatura de referencia (IntechOpen, Chapter 69568).

3. Análisis Exploratorio de Datos (EDA)

Se realizó un análisis estadístico descriptivo sobre cada columna usando el método `.describe()` de PySpark, obteniendo `count`, `mean`, `stddev`, `min` y `max` para cada parámetro. Adicionalmente, se generaron tres gráficas de línea para visualizar la distribución temporal/espacial de los parámetros a lo largo de las observaciones del dataset:

- Gráfica 1 — `DO` vs `pH`: Permite observar la relación entre el oxígeno disuelto y el nivel de acidez/basicidad del agua. Variaciones de `pH` fuera del rango `[7, 8.5]` sugieren condiciones subóptimas para la vida acuática.
- Gráfica 2 — `BOD` vs `Nitratos/Nitritos`: Indicadores de contaminación orgánica. Picos elevados de `BOD` junto con altas concentraciones de nitrógeno señalan estados con mayor carga de materia orgánica en descomposición.
- Gráfica 3 — `Conductividad` vs `Material Fecal`: La conductividad alta puede indicar presencia de sales o iones disueltos; combinada con coliformes fecales elevados, apunta a fuentes de contaminación directa.

Las gráficas del notebook entregado incluyen etiquetas descriptivas en los ejes X e Y, mejorando la legibilidad respecto al notebook base.

4. Cálculo del Índice de Calidad del Agua (WQI)

4.1 Rangos de calidad por parámetro

Para cada parámetro fisicoquímico se creó una columna de rango de calidad (qr) con valores discretos {0, 40, 60, 80, 100}, donde 100 representa la mejor condición posible para ese parámetro y 0 la peor. Los umbrales fueron tomados directamente de la referencia bibliográfica (IntechOpen).

4.2 Pesos ponderados y cálculo del WQI

El WQI se calcula como suma ponderada de los rangos de calidad individuales: $WQI = \sum(qr_i \times w_i)$. Los pesos asignados a cada parámetro son los siguientes:

Parámetro	Variable qr	Peso (w)	Contribución máx.
DO	qrDO	0.281	28.1
FECAL_COLIFORM	qrFecal	0.281	28.1
CONDUCTIVITY	qrCOND	0.234	23.4
pH	qrPH	0.165	16.5
NITRATE_N_NITRITE_N	qrNN	0.028	2.8
BOD	qrBOD	0.009	0.9
TOTAL	—	$0.998 \approx 1.0$	99.8

Los parámetros DO y Coliformes Fecales tienen el mayor peso (0.281 cada uno), lo cual es consistente con su relevancia sanitaria directa: el oxígeno disuelto determina la viabilidad de ecosistemas acuáticos, mientras que los coliformes fecales son el indicador más directo de contaminación por aguas residuales.

4.3 Categorías de calidad

Con base en el valor calculado de WQI, cada observación fue clasificada en cinco categorías de calidad:

Categoría	Rango WQI	Tipo de Agua	Pesos aplicados
Excelente	0 – 25	Agua Dulce (Potable)	$\sum(qr \times w) \in [0,25)$
Buena	25 – 50	Agua Moderada	$\sum(qr \times w) \in [25,50)$
Baja	50 – 75	Agua Dura	$\sum(qr \times w) \in [50,75)$
Muy Baja	75 – 100	Agua Muy Dura	$\sum(qr \times w) \in [75,100)$
Inadecuada	> 100	Agua Residual	$\sum(qr \times w) > 100$

Esta categorización permite convertir el problema de regresión continua (predicción del valor WQI) en un problema interpretable para tomadores de decisiones en política de agua potable.

5. Visualización Geográfica — Mapa de la India

Se integró la información del WQI por estado con datos geospaciales vectoriales (shapefiles Indian_States) usando la biblioteca GeoPandas. El proceso incluyó:

- Armonización de nombres de estados entre el dataframe Spark y el shapefile (corrección de caracteres especiales como '&' en nombres de estados).
- Normalización tipográfica mediante F.initcap() para garantizar la coincidencia en el join.
- Merge outer entre el GeoDataFrame y el DataFrame convertido a Pandas, usando 'STATE' como clave.
- Imputación de valores WQI nulos (estados sin datos en el CSV) con la mediana del dataset, para evitar estados en blanco en la visualización.
- Renderizado del mapa con cmap='Grays' y esquema de clasificación userdefined con bins [0, 25, 50, 75, 100], acompañado de etiquetas numéricas del WQI en cada estado (color verde, bold, fontsize=11).

La visualización permite identificar geográficamente qué regiones de la India presentan mayor problemática en calidad del agua, facilitando la priorización de intervenciones.

6. Modelo de Predicción — Red Neuronal Keras

6.1 Arquitectura del modelo

Se implementó una red neuronal densa (Fully Connected / MLP) con la siguiente arquitectura:

Capa	Tipo	Neuronas	Activación	Parámetros
Entrada + Dense 1	Dense	350	ReLU	$6 \times 350 + 350 = 2,450$
Dense 2	Dense	350	ReLU	$350 \times 350 + 350 = 122,850$
Dense 3	Dense	350	ReLU	$350 \times 350 + 350 = 122,850$
Salida	Dense	1	Linear	$350 \times 1 + 1 = 351$
TOTAL	—	—	—	$\approx 248,501$ paráms.

La arquitectura utiliza tres capas ocultas con activación ReLU para capturar relaciones no lineales entre los rangos de calidad individuales y el WQI resultante. La capa de salida usa activación lineal, lo que es correcto para tareas de regresión (predicción de un valor continuo).

6.2 Hiperparámetros y configuración del entrenamiento

Hiperparámetro	Valor	Justificación
Épocas	200	Convergencia observable en curva de pérdida
Batch size	81	Ajuste empírico sobre ~30 registros
Optimizador	Adam	Adaptativo, robusto en problemas de regresión

Learning rate	0.001	Valor estándar para Adam
Función de pérdida	MSE	Apropiada para regresión continua
Métrica	MSE	Minimización del error cuadrático en WQI
Split entren./prueba	80% / 20%	Convención estándar sklearn train_test_split
random_state	1	Reproducibilidad del experimento

El optimizador Adam es una elección sólida para este tipo de problema: combina momentum adaptativo con tasas de aprendizaje por parámetro, lo que acelera la convergencia y reduce la sensibilidad a la escala de los features. La función de pérdida MSE (Error Cuadrático Medio) penaliza más fuertemente las predicciones con gran error, lo cual es adecuado cuando se busca minimizar desviaciones del WQI real.

6.3 Datos de entrenamiento y prueba

El dataset fue dividido usando train_test_split de scikit-learn con una proporción 80%/20% y random_state=1 para reproducibilidad. Las features de entrada son los 6 rangos de calidad (qrPH, qrDO, qrCOND, qrBOD, qrNN, qrFecal) y la variable objetivo es WQI.

Observación importante: dado que el WQI es una combinación lineal de los rangos de calidad ponderados ($WQI = \sum q r_i \times w_i$), existe una relación matemáticamente determinista entre las features y el target. Esto significa que el modelo debería ser capaz de aprender esta relación con alta precisión, y cualquier error residual proviene del sobreajuste o de la naturaleza discreta de los qr.

6.4 Curva de pérdida

El notebook incluye una gráfica de la evolución de la función de pérdida (MSE) a lo largo de las 200 épocas de entrenamiento. Se espera que la curva muestre una caída pronunciada en las primeras épocas y una estabilización posterior, lo que indica convergencia del modelo. Etiquetas de eje añadidas en el notebook del equipo: eje X = 'Épocas', eje Y = 'Pérdidas'.

7. Análisis de Resultados

7.1 Resultados del cálculo WQI

El cálculo del WQI sobre el dataset de ríos de la India revela una variedad de condiciones de calidad distribuidas entre los distintos estados. Los estados con mayor carga de coliformes fecales y menor oxígeno disuelto tienden a producir índices WQI elevados (categorías 'Baja' o 'Inadecuada'), mientras que estados con mejores parámetros fisicoquímicos obtienen categorías 'Excelente' o 'Buena'.

Es fundamental destacar la advertencia explícita del notebook: el dataset contiene promedios estatales (no mediciones por punto de captación), lo que implica que el WQI calculado no es una guía operativa de calidad de agua potable, sino un indicador de referencia académica para el ejercicio de modelamiento.

7.2 Resultado del modelo Keras

El modelo entrenado predice el valor continuo de WQI a partir de los 6 rangos de calidad individuales. Dado que el WQI es una función lineal de estos rangos (con coeficientes fijos), una red neuronal con suficiente capacidad debería lograr un MSE muy bajo (teóricamente cercano a 0 en entrenamiento). En la práctica:

- La curva de pérdida debería mostrar convergencia rápida dado que la relación subyacente es lineal y los datos son consistentes.
- Si el MSE de prueba es significativamente mayor al de entrenamiento, esto indicaría sobreajuste — posible dado el tamaño pequeño del dataset (~30 estados).
- La arquitectura con 3 capas de 350 neuronas es considerablemente sobredimensionada para un dataset de esta escala, lo que aumenta el riesgo de sobreajuste.

Para un análisis completo de resultados se recomienda reportar: MSE de entrenamiento, MSE de prueba, R^2 (coeficiente de determinación) y MAE (Error Absoluto Medio), disponibles mediante `sklearn.metrics`.

7.3 Limitaciones identificadas

- El dataset es reducido (~30 registros estatales), lo que limita la capacidad generalizadora del modelo.
- Los rangos qr son variables discretas con pocos valores posibles {0, 40, 60, 80, 100}, lo que puede generar clases desbalanceadas en algunas variables.
- No se implementó validación cruzada (cross-validation), por lo que los resultados de una sola partición pueden ser sensibles a la semilla aleatoria.
- El modelo de Regresión Lineal con MLlib (mencionado en la metodología) no fue implementado, lo que impide una comparativa directa entre los enfoques estadístico clásico y neuronal.

8. Conclusiones

El presente trabajo demuestra la viabilidad de aplicar técnicas de Procesamiento de Alto Volumen de Datos con PySpark para el análisis y predicción de la calidad del agua, siguiendo la metodología CRISP-DM adaptada a entornos distribuidos. Las principales conclusiones son:

- PySpark como entorno de procesamiento distribuido permite manejar datos de calidad hídrica de forma eficiente, aplicando transformaciones funcionales (`withColumn`, `cast`, `lambdas RDD`) que son transparentes al volumen de datos subyacente.
- El índice WQI calculado según los pesos bibliográficos de referencia constituye una métrica interpretable y multidimensional que resume en un solo valor la calidad del agua en función de seis parámetros críticos, con DO y Coliformes Fecales como factores dominantes (peso combinado del 56.2%).
- La visualización geoespacial sobre el mapa de la India añade una dimensión analítica valiosa, permitiendo identificar patrones regionales de calidad hídrica que correlacionan con condiciones socioeconómicas y de infraestructura sanitaria.
- El modelo de red neuronal Keras con arquitectura MLP es capaz de aprender la relación entre los rangos de calidad individuales y el WQI agregado. Sin embargo, dado el

carácter determinista de esta relación y el tamaño reducido del dataset, la arquitectura implementada es sobredimensionada para el problema. Una regresión lineal simple sería igualmente efectiva y más interpretable.

- La comparación entre el notebook entregado y el de referencia evidencia mejoras sustanciales en la calidad de la documentación: ejes de gráficas etiquetados, celdas de código ejecutables (en lugar de pseudo-código), y cierre apropiado de la sesión Spark.

Como trabajo futuro se recomienda: implementar el modelo de Regresión Lineal con MLlib para comparación, incorporar métricas explícitas (R^2 , MAE, RMSE), aplicar técnicas de regularización (Dropout, L2) para mitigar el sobreajuste, y ampliar el dataset integrando mediciones históricas para mejorar la robustez del modelo.

9. Referencias

- [1] Sutadian, A. D., et al. (2016). *Development of a water quality index for rivers in West Java Province, Indonesia*. IntechOpen, Chapter 69568. <https://www.intechopen.com/chapters/69568>
- [2] Central Pollution Control Board India — National Water Quality Monitoring Programme (RiverIndia Dataset).
- [3] Apache Spark MLlib Documentation. <https://spark.apache.org/docs/latest/ml-guide.html>
- [4] Chollet, F. (2021). *Deep Learning with Python, 2nd Edition*. Manning Publications.
- [5] Corredor, J. (2026). Material de clase: Procesamiento de Alto Volumen de Datos. Pontificia Universidad Javeriana, Bogotá.